


**Разработка гибридной модели для предсказания следующего элемента в пользовательской сессии на основе поведенческих паттернов и контентных эмбедингов видео.**

**Сравнение четырёх классов рекомендательных моделей на датасете VK-LSVD**

Итоговый проект по модулю "Машинное обучение: фундаментальные инструменты и практики"



Автор: Игорь Каукин, группа: AML-68

Куратор: Максим Зайкин

Ментор: Екатерина Прохорова

# Контекст задачи

**Рекомендательные системы** — ключевой инструмент современных видеоплатформ.

- Пользователь не формулирует запрос — система **проактивно** предлагает контент
- Основа — **история взаимодействий**: просмотры, реакции, время просмотра
- Цель — максимизировать вероятность **целевого действия**

**Задача:** предсказать, какой ролик пользователь посмотрит **следующим**.

# Постановка задачи

**Дано:**

- $\mathcal{U}$  — пользователи,  $\mathcal{I}$  — видеоролики
- $H_u = [i_1, i_2, \dots, i_t]$  — история взаимодействий пользователя  $u$

**Требуется:** для каждого  $u$  построить функцию скоринга

$$f_u : \mathcal{I} \setminus H_u \rightarrow \mathbb{R}$$

и вернуть топ- $K$  роликов:

$$\text{top-}K(u) = \underset{i \in \mathcal{I} \setminus H_u}{\operatorname{argtop-}K} f_u(i)$$

**Метрики:** Recall@K, NDCG@K, MRR@K

# Данные: VK-LSVD

**VK-LSVD** — открытый промышленный датасет коротких видео (AI VK Research).

- Полная версия: **40+ млрд** взаимодействий, 10M пользователей, 20M видео
- В работе: **подвыборка** `up0.001_ip0.001`
- **25 недель**: train — 0..24, validation — 25
- ~600 тыс. взаимодействий/неделю, ~2.6 ГБ

**Разметка pos/neg:**

- **Позитив**: `timespent >= 5` сек **или** любая реакция, **при отсутствии** `dislike`
- **Негатив**: всё остальное

**Особенность**: нет timestamp — хронология по порядку строк в parquet.

# Четыре модели — сравнение

| Модель      | Класс          | Что учитывает                      |
|-------------|----------------|------------------------------------|
| MostPopular | неперсональный | глобальная популярность            |
| FPMC        | марковский     | последний item + вкус пользователя |
| LightGCN    | графовый       | коллаборативные связи              |
| SASRec      | sequential     | всю историю через self - attention |

**Гипотеза:** разные классы моделей предпочтительны для **разных групп пользователей** по длине истории.

# Архитектура FPMC

*Factorized Personalized Markov Chains*

$$\text{score}(u, i, j) = \underbrace{p_u^\top q_j}_{\text{MF}} + \underbrace{\sum_d BU_{u,d} T_{i,d} T_{j,d}}_{\text{MC}}$$


- **MF** — персональные предпочтения
- **MC** — переходы «последний → следующий» с учётом пользователя

**Обучение:** BPR-loss, negative sampling

**Особенность:** учитывает **только последний** item.


# Архитектура SASRec

*Self-Attentive Sequential Recommendation*




# Архитектура LightGCN

*Light Graph Convolutional Networks*




# Гибридный ансамбль



**Идея:** разные модели — для разных пользователей.

- **cold** (короткая история) → FPMC
- **warm** (средняя) → MostPopular
- **hot** (длинная) → SASRec

# Пайплайн обучения



# Результаты

**Smoke-прогон:** 5 недель, 1 эпоха, подвыборка

*Миссия этого прогона была только одна: сравнить модели на доступном автору железе.*

| Группа | Модель             | Recall@10     | NDCG@10       | MRR@10        |
|--------|--------------------|---------------|---------------|---------------|
| cold   | MostPopular        | 0.0019        | 0.0014        | 0.0027        |
| cold   | <b>FPMC</b>        | <b>0.0062</b> | <b>0.0120</b> | 0.0101        |
| cold   | LightGCN           | 0.0047        | 0.0082        | 0.0014        |
| cold   | SASRec             | 0.0057        | 0.0061        | <b>0.0141</b> |
| warm   | <b>MostPopular</b> | <b>0.0144</b> | <b>0.0141</b> | 0.0112        |
| warm   | FPMC               | 0.0032        | 0.0057        | 0.0008        |
| warm   | LightGCN           | 0.0040        | 0.0061        | 0.0019        |
| warm   | SASRec             | 0.0032        | 0.0048        | <b>0.0162</b> |
| hot    | MostPopular        | 0.0096        | 0.0233        | 0.0052        |
| hot    | FPMC               | 0.0018        | 0.0102        | 0.0039        |
| hot    | LightGCN           | 0.0039        | 0.0178        | 0.0022        |
| hot    | <b>SASRec</b>      | 0.0095        | <b>0.0237</b> | <b>0.0462</b> |

# Выводы

## Основные результаты:

1. **FPMC** — лучший на **cold** (короткая история)
2. **MostPopular** — силён на **warm**
3. **SASRec** — лучший на **hot**, лидер по MRR
4. **LightGCN** — недообучен на 1 эпохе, требует больше

**Главное:** ни одна модель не выигрывает везде → **гипотеза гибридного ансамбля подтверждается.**

## Планы:

- Адаптивная сегментация (границы под размер окна обучения).
- Fallback на обеих границах (когда размер истории не позволяет уверенно отнести пользователя к конкретной группе, можно предусмотреть специальную стратегию по добавлению прогноза от Most Popular модели).
- LightGCN на 10+ эпохах (модель не смогла проявить себя из-за скромности использованных в опыте ресурсов).
- Проверка инсайтов найденных в EDA (результаты EDA в проекте не использовались, но ознакомиться с ними можно в файле `notebooks/01_eda.ipynb`).