

Разработка гибридной модели для предсказания следующего элемента в пользовательской сессии на основе поведенческих паттернов и контентных эмбедингов видео.

На примере датасета VK-LSVD.

Куратор: Максим Зайкин

Ментор: Екатерина Прохорова

Слушатель: Игорь Каукин, группа AML-68

Сентябрь, 2026

Содержание

Введение	2
Постановка задачи	2
Формализация	2
Целевые метрики	3
Рассматриваемые подходы	3
Гибридный ансамбль	3
Ограничения и допущения	3
Описание данных и их особенностей	3
Состав и структура данных	4
Обработка данных	5
Единая разметка позитив/негатив	5
Общие преобразования	5
Модель-специфичные преобразования	5
Negative sampling	5
Описание возможных решений и планируемая архитектура	6
Классификация подходов	6
Неперсональные подходы	6
Персональные подходы на основе сходства	6
Sequential подходы (прогнозирование следующего на основе истории)	7
Планируемая архитектура	8
Гибридный ансамбль с роутингом	9
Обучение моделей и валидация	9
Стратегия разделения данных	9
Функция потерь и оптимизация	9
Механизм Negative Sampling	9
Процедура валидации и метрики	10
Построение гибридного ансамбля	10
Результаты и анализ	10
Сводная таблица метрик по группам пользователей	10

Формирование гибридного ансамбля	11
Ограничения и выводы	11
Заключение	11
Список литературы	12

Введение

С распространением интернета и его превращением во «всемирную сеть» бизнес начал активно использовать его как посредника в коммуникации с потенциальными клиентами.

Взаимодействие может быть организовано на разных уровнях:

- **Непосредственное представительство.** Бизнес размещает сайт в сети, и всё взаимодействие «клиент–продавец» происходит через него. Способ привлечения клиента на сайт не анализируется.
- **Продвижение сайта.** Бизнес взаимодействует с поисковыми системами для максимального повышения видимости сайта в ответ на поисковые запросы пользователей. Помимо индексирования контента, современные поисковые системы учитывают семантическую близость запроса и документа, включая в выдачу ссылки, не имеющие точного совпадения с запросом, но близкие по тематике. Если рассматривать страницы в индексе как «товар», а упоминание темы запроса на странице — как «взаимодействие», то подбор близких по теме страниц становится схож с работой рекомендательных алгоритмов.
- **Персонализированный подбор рекомендаций.** Система формирует выдачу, максимально ориентированную на текущие предпочтения и потребности конкретного пользователя. Ключевая особенность рекомендательной системы — проактивность: она не ждёт явного запроса пользователя, а заранее провоцирует его на совершение целевого действия. Для этого система собирает историю всех потенциально значимых действий: какие разделы просматривал, какие детали уточнял (`click_on_author`, `open_comments`), как долго смотрел (`timespent`), что одобрил (`like`) или отверг (`dislike`), и многое другое. На основе этой информации система прежде всего показывает пользователю тот контент, который с наибольшей вероятностью его заинтересует, и только затем — всё остальное. Кроме переупорядочивания выдачи, рекомендации могут учитываться при формировании персональных маркетинговых акций для увеличения вероятности целевого действия.

Рекомендательная система — это информационная система, которая отслеживает действия пользователя, способные помочь предсказать, какая информация или продукт сейчас наиболее им востребованы. Вся накопленная информация агрегируется в пользовательский профиль и используется для формирования персонализированной выдачи.

Алгоритм рекомендательной системы — это алгоритм, предназначенный для автоматического подбора релевантных текущим интересам пользователя предложений.

Постановка задачи

В рамках данного проекта рассматривается задача **персонализированного предсказания следующего выбора пользователя** на видеохостинге. Формально, для каждого пользователя u по истории его взаимодействий с видеороликами необходимо сформировать упорядоченный список из K роликов, которые он с наибольшей вероятностью готов просмотреть следующими.

Формализация

Пусть:

- $\mathcal{U}$ — множество пользователей.
- $\mathcal{I}$ — множество видеороликов.
- $H_u = [i_1, i_2, \dots, i_t]$ — упорядоченная по времени история взаимодействий пользователя $u \in \mathcal{U}$, где $i_k \in \mathcal{I}$ — ролик, просмотренный на шаге k .

Задача: для каждого пользователя u с историей H_u построить функцию скоринга:

$$f_u : \mathcal{I} \setminus H_u \rightarrow \mathbb{R}$$

и вернуть топ- K роликов с наибольшими значениями:

$$\text{top-}K(u) = \underset{i \in \mathcal{I} \setminus H_u}{\operatorname{argtop-}K} f_u(i)$$

где $\mathcal{I} \setminus H_u$ — множество роликов, с которыми пользователь не взаимодействовал в тренировочном периоде (S_u включает как позитивные, так и негативные взаимодействия).

Целевые метрики

Качество рекомендаций оценивается по стандартным для задачи next-item prediction метрикам:

- **Recall@K** — доля верных айтемов из ground truth, попавших в топ- K .
- **HitRate@K** — доля пользователей, у которых хотя бы один верный айтем попал в топ- K .
- **NDCG@K** — нормализованный кумулятивный выигрыш, учитывающий позицию правильного ответа в выдаче.
- **MRR (Mean Reciprocal Rank)** — среднее обратное ранга первого релевантного элемента.

Оценка производится на отложенной тестовой выборке с разделением по времени: для каждого пользователя последние взаимодействия используются как ground truth, предыдущие — как обучающая история.

Рассматриваемые подходы

В работе сравниваются четыре класса алгоритмов:

1. **MostPopular** — неперсональный baseline, ранжирующий ролики по глобальной частоте позитивных взаимодействий в обучающей выборке.
2. **FPMC (Factorized Personalized Markov Chains)** — комбинация матричной факторизации (персональные предпочтения) и марковских переходов первого порядка (контекст последнего просмотра).
3. **SASRec (Self-Attentive Sequential Recommendation)** — sequential-модель на основе self-attention, кодирующая всю упорядоченную историю пользователя.
4. **LightGCN (Light Graph Convolutional Networks)** — модель на основе графовых сверток, обучающая персональные эмбединги пользователей и роликов на позитивных ребрах графа взаимодействий.

Гибридный ансамбль

Помимо сравнения моделей по отдельности, в работе строится гибридный ансамбль, назначающий каждому пользователю наиболее подходящую модель на основе размера его истории взаимодействий в тренировочном периоде. Пользователи разделяются на три группы: холодные, тёплые и горячие. Для каждой группы выбирается модель, показавшая наилучшие метрики на валидационной выборке.

Примечание: в текущей реализации деплой в prod ни как не рассмотрен, система училась один раз, на ограниченной подвыборке, и по результатам обучения задано жесткое соответствие группы пользователя модели, которая используется для получения его прогноза.

Ограничения и допущения

- В рамках проекта используются как неявные сигналы (длительность просмотра timespent), так и явные реакции пользователя (like, dislike, share, bookmark, click_on_author, open_comments). Единая функция разметки агрегирует оба типа сигналов: действие считается позитивным при длительном просмотре или наличии любой позитивной реакции; негативным — при явном дизлайке или коротком просмотре без позитивных сигналов.
- Все модели обучаются на **одних и тех же временных сплитах** для корректного сравнения.
- Из выдачи исключаются ролики, уже просмотренные пользователем.

Описание данных и их особенностей

VK-LSVD (Large Short-Video Dataset) — это один из крупнейших открытых промышленных датасетов для рекомендательных систем коротких видео, опубликованный командой AI VK Research. Он создан на основе реального пользовательского опыта и содержит более 40 миллиардов взаимодействий.

В рамках данного проекта используется подвыборка VK-LSVD с параметрами `ur0.001_ip0.001` (0.1% случайных пользователей и 0.1% наиболее популярных видео). Это позволяет протестировать гипотезы на ограниченном объеме данных (~40 млн взаимодействий, ~10000 пользователей, ~20000 видео) без необходимости развёртывания распределённой инфраструктуры.

Состав и структура данных

Датасет разделен на три основных компонента (таблицы) и отдельный массив контентных векторов:

- Взаимодействия (Interactions):
 - `user_id` и `item_id` — обезличенные ID пользователя и видео.
 - `timespent` — точное время просмотра ролика в секундах (в диапазоне от 0 до 255).
 - Бинарные сигналы обратной связи (Feedback): `like` (лайк), `dislike` (дизлайк), `share` (поделиться), `bookmark` (сохранил в закладки), `click_on_author` (переход на страницу автора), `open_comments` (открытие комментариев).
 - Контекст показа: `place` (24 точки входа: лента, поиск, профиль и т.д.), `platform` (11 вариантов: Android, Web, Smart TV и др.), `agent` (29 вариантов клиентов/браузеров).
- Метаданные пользователей (Users metadata):
 - Демография: `age` (возраст от 18 до 70 лет) и `gender` (пол).
 - Геопозиция: `geo` (80 укрупненных регионов).
 - `train_interactions_rank` — ранг популярности пользователя для удобного сэмплинга.
- Метаданные видео (Items metadata):
 - `author_id` — ID автора ролика.
 - `duration` — длительность видео в секундах.
 - `train_interactions_rank` — ранг популярности контента.
- Контентные эмбединги (Embeddings):
 - Для каждого видео доступен 64-мерный вектор (`float16[64]`), обученный строго на контенте (само видео, аудиодорожка, описание) без добавления коллаборативных сигналов.

Ключевые особенности VK-LSVD:

- Большой масштаб:
 - Массив охватывает действия 10 миллионов пользователей и почти 20 миллионов коротких видео за 6 последовательных месяцев.
- Плотный и быстрый фидбэк:
 - В отличие от музыки или кино, короткие видео смотрят сессионно и быстро. Это генерирует высокую плотность сигналов, где даже отсутствие явного like-a (но долгий просмотр или, наоборот, мгновенный swipe) — ценная информация.
- Конфигурируемые подмножества (Умный сэмплинг):
 - Датасет имеет большой объем, поэтому создатели предусмотрели систему гибкой нарезки под ресурсы любого ПК. Используя параметры ранга популярности (`urX`, `ipX`), можно скачать, например, `ur0.01_ip0.01` (1% случайных пользователей и 1% самых популярных видео), чтобы быстро протестировать гипотезы.
- Упорядоченные эмбединги (Variable Width):
 - Компоненты в 64-мерных векторах упорядочены по значимости. Вы можете взять только первые N компонентов (например, 16 из 64), чтобы сэкономить память и ускорить вычисления — при этом скалярное произведение все равно будет аппроксимировать исходную косинусную близость. (В конфигурации для `sasrec` модели можно задать параметр `emb_width`, который позволит брать только часть вектора эмбедингов.)
- Отсутствие явных временных меток:
 - В датасете отсутствует колонка `timestamp`. Временной порядок взаимодействий восстанавливается по порядку строк в `parquet`-файлах: строки упорядочены по возрастанию времени, а файлы разделены по неделям (`week_00 ... week_25`). Это допущение критично для последовательных моделей (FPMC, SASRec), где порядок истории имеет значение.
- Полная конфиденциальность:
 - Все категориальные признаки переведены в стабильные целочисленные ID (Integer IDs), обратный маппинг отсутствует, что защищает личные данные пользователей.

Примечание. В рамках данного проекта используются только взаимодействия (`user_id`, `item_id`, `timespent`, бинарные сигналы) и контентные эмбединги. Контекстные признаки (`place`, `platform`, `agent`) и метаданные пользователей/видео

(age, gender, geo, author_id, duration) в моделях не задействованы, но могут быть использованы в дальнейших исследованиях.

Обработка данных

Датасет VK-LSVD создавался специально для проверки гипотез и соревнований, поэтому исходные данные не требуют сложной очистки или нормализации. Однако для приведения данных к виду, пригодному для обучения моделей, выполняется ряд преобразований **на лету** (без сохранения промежуточных результатов на диск, поскольку размер подвыборки позволяет пересчитывать данные при каждом запуске быстрее, чем читать их с диска).

Единая разметка позитив/негатив

Все модели используют **единый механизм разметки** (`common/labels.py`), агрегирующий неявные и явные сигналы:

- **Позитивное действие** (`label = 1`): длительность просмотра `timespent` ≥ 5 секунд ИЛИ наличие хотя бы одной позитивной реакции (`like, share, bookmark, click_on_author, open_comments`).
- **Негативное действие** (`label = 0`): не является позитивным И (`timespent < 5` секунд ИЛИ явный `dislike`).

Применяется правило «**позитив побеждает**»: при наличии любого позитивного сигнала действие считается позитивным, даже если стоит `dislike`. Null-значения в полях реакций трактуются как `False`, null в `timespent` — как 0. Строки, не попавшие ни в одну категорию, отбрасываются.

Общие преобразования

Для всех моделей выполняются следующие шаги:

1. **Построение компактных индексов.** Исходные `user_id` и `item_id` отображаются в плотные целочисленные индексы $0 \dots N-1$ (по отсортированным ID для воспроизводимости).
2. **Восстановление хронологии.** Поскольку в датасете отсутствует колонка `timestamp`, порядок взаимодействий определяется порядком строк в `parquet`-файлах. Перед группировкой по `user_id` данные явно сортируются по глобальному индексу строки.
3. **Построение множества *seen*.** Для каждого пользователя собирается множество всех айтемов, с которыми он взаимодействовал в тренировочном периоде (и позитивные, и негативные). Это множество используется для исключения уже увиденного из кандидатов при инференсе и расчёте метрик.
4. **Построение валидационной выборки.** Из валидационной недели отбираются только позитивные айтемы, которых нет в `seen` пользователя (иначе предсказывать нечего).

Модель-специфичные преобразования

- **MostPopular.** Подсчёт популярности каждого айтема как числа позитивных взаимодействий в тренировочном периоде.
- **FPMC.** Построение триплетов (`user, last_item, next_item`) по последовательным позитивным айтемам в истории пользователя.
- **LightGCN.** Построение двудольного графа «пользователь–ролик» по позитивным рёбрам и вычисление симметрично нормализованной матрицы смежности $\tilde{A} = D^{-1/2} A D^{-1/2}$.
- **SASRec.** Построение слайдинг-окон: для каждого позитивного айтема целевой недели формируется сэмпл (история за последние `N` недель, целевой айтем, явные негативы).

Negative sampling

Для обучения моделей с BPR-функцией потерь (FPMC, LightGCN, SASRec) используется единый механизм `negative sampling` (`common/negatives.py`):

- **Приоритет:** случайный айтем из явных негативов пользователя (`skip/dislike`), если они есть.
- **Иначе:** случайный айтем из всего словаря.

- **Критично:** из кандидатов исключаются **все позитивные айтемы пользователя** (а не только текущий `pos_item`), чтобы модель не обучалась на «негативах», которые на самом деле являются позитивными.

Описание возможных решений и планируемая архитектура

Классификация подходов

В литературе и практике выделяют три основных класса рекомендательных систем, расположенных по возрастанию сложности и персонализации:

1. **Неперсональные (популярностные) подходы.**
2. **Персональные на основе сходства (коллаборативная и контентная фильтрация).**
3. **Персональные на основе прогнозирования последовательностей (sequential recommendation).**

Неперсональные подходы

Идея. Рекомендовать контент, который популярен в целом или в определённой группе, без учёта индивидуальной истории пользователя.

Типичные варианты:

- **Global Most Popular** — топ-К самых просматриваемых роликов на платформе.
- **Trending / Recent Popular** — ролики с наибольшим числом просмотров за последнее время (час, день, неделя).
- **Popular in Category** — популярные ролики в категории, которую пользователь просматривал ранее.
- **Editorial / Curated** — вручную отобранные редакцией рекомендации (для новостных и медиа-платформ).

Преимущества:

- Простота реализации и интерпретации.
- Не требуют истории пользователя — работают для cold-start (новые пользователи).
- Устойчивы к шуму в индивидуальных данных.

Недостатки:

- Отсутствие персонализации — все пользователи получают одинаковую выдачу.
- Не учитывают индивидуальные предпочтения и контекст сессии.
- Склонны к усилению popularity bias (популярное становится ещё популярнее).

Применение. Часто используются как fallback для новых пользователей или как дополнительный сигнал в гибридных системах.

Персональные подходы на основе сходства

Идея. Использовать историю взаимодействий пользователя для поиска похожих пользователей или похожих items и рекомендации того, что понравилось «похожим».

Коллаборативная фильтрация (Collaborative Filtering, CF) User-based CF. Если пользователь A похож на пользователя B по истории просмотров, то ролики, понравившиеся B , могут заинтересовать A .

Item-based CF. Если пользователь смотрел ролик X , то ему могут понравиться ролики, похожие на X по паттернам совместных просмотров («пользователи, смотревшие X , также смотрели Y »).

Матричная факторизация (Matrix Factorization, MF). Пользователи и items представляются в виде векторов в латентном пространстве:

$$\hat{y}_{u,i} = \langle p_u, q_i \rangle = p_u^T q_i$$

где p_u - эмбединг пользователя, q_i - эмбединг item, а $\hat{y}_{u,i}$ - предсказанный score после взаимодействия.

Преимущества:

- Учитывают индивидуальные предпочтения.
- Не требуют метаданных о контенте (работают только по логам взаимодействий).

Недостатки:

- Cold-start для новых пользователей и items (нет истории — нет рекомендаций).
- Не учитывают порядок и контекст взаимодействий.
- Могут страдать от sparsity (разреженности матрицы взаимодействий).

Контентная фильтрация (Content-Based Filtering) **Идея.** Рекомендовать items, похожие по содержанию на те, которые пользователь уже смотрел.

Признаки:

- Метаданные: категория, теги, автор, длительность, год выпуска.
- Текстовое описание: название, описание, транскрипты.
- Визуальные признаки: обложки, ключевые кадры (для видео).

Методы:

- Векторное представление контента (TF-IDF, embeddings).
- Косинусное сходство между профилями пользователя и items.

Преимущества:

- Работает для новых items (если есть метаданные).
- Интерпретируемость: можно объяснить рекомендацию («потому что вы смотрели похожее»).

Недостатки:

- Требуется качественных метаданных.
- Не учитывает коллективные паттерны («другим понравилось»).
- Склонна к over-specialization (рекомендует только очень похожее).

Гибридные подходы **Идея.** Комбинировать коллаборативную и контентную фильтрацию для компенсации недостатков каждого подхода.

Варианты:

- **Weighted hybrid** — взвешенная сумма scores от CF и content-based.
- **Feature combination** — объединение признаков из обоих подходов в одной модели.
- **Cascade hybrid** — последовательная фильтрация: сначала CF, затем content-based для уточнения.

Преимущества:

- Более устойчивы к cold-start и sparsity.
- Часто показывают лучшее качество, чем отдельные компоненты.

Недостатки:

- Сложнее в реализации и отладке.
- Требуют больше вычислительных ресурсов.

Sequential подходы (прогнозирование следующего на основе истории)

Идея. Учитывать не только факт взаимодействия, но и порядок и контекст предыдущих действий пользователя для предсказания следующего.

Ключевое отличие от классической CF. Традиционные методы предполагают, что взаимодействия независимы и одинаковы по распределению (i.i.d.). Sequential-подходы явно моделируют зависимость:

$$P(i_{t+1} | i_1, i_2, \dots, i_t) \neq P(i_{t+1})$$

Марковские модели **First-order Markov Chains.** Вероятность следующего item зависит только от последнего:

$$P(i_{t+1} | i_t)$$

Персонализированные марковские цепи (FPMC). Комбинация MF и персонализированных марковских переходов через CP-декомпозицию тензора переходов:

$$\text{score}(u, l, i) = \langle U_u, V_i \rangle + \sum_d BU_{u,d} \cdot T_{l,d} \cdot T_{i,d}$$

где $\langle U_u, V_i \rangle$ — матричная факторизация (вкус пользователя), а сумма — CP-декомпозиция тензора переходов «пользователь $\times$ последний $\times$ следующий» с низкоранговыми факторами BU (пользователь) и T (айтем, общий для «последнего» l и «следующего» i).

Преимущества:

- Учитывают краткосрочный контекст (последний просмотр).
- Проще в обучении, чем глубокие sequential-модели.

Недостатки:

- Не учитывают длинную историю (только последний item).
- Могут быть недостаточно выразительными для сложных паттернов.

Модели на основе глубокого обучения RNN / GRU / LSTM. Рекуррентные сети для кодирования последовательности:

$$h_t = RNN(e_{i_t}, h_{t-1})$$

Self-Attention (SASRec, BERT4Rec). Механизм внимания для взвешивания важности разных элементов истории:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

где d_k — размерность ключей (key dimension).

Графовые подходы (LightGCN, SR-GNN). Построение графа взаимодействий и агрегация информации от соседей.

Преимущества:

- Учитывают длинную историю и сложные паттерны.
- Могут выявлять неочевидные зависимости (смена интересов, сессионные паттерны).

Недостатки:

- Требуют больше данных для обучения.
- Сложнее в настройке и интерпретации.
- Вычислительно дороже.

Планируемая архитектура

В рамках данного проекта реализуется архитектура с комбинацией подходов:

- **Baseline (MostPopular).** Неперсональный рейтинг для оценки минимального порога качества и fallback для cold-start пользователей.
- **FPMC.** Персональный sequential-baseline с учётом последнего просмотра.
- **SASRec.** Основная sequential-модель с self-attention для кодирования полной истории.
- **LightGCN.** Графовая модель для оценки вклада collaborative filtering без учёта порядка.

Сравнение подходов проводится по метрикам **Recall@K**, **NDCG@K**, **MRR** на отложенной тестовой выборке с временным разделением. Дополнительно анализируется качество на сегментах пользователей с разной длиной истории (cold / warm / hot).

Гибридный ансамбль с роутингом

Помимо сравнения моделей по отдельности, анализируется качество на сегментах пользователей с разной длиной истории (cold / warm / hot). Для каждой группы выбирается модель, показавшая наилучшие метрики на валидационной выборке, что позволяет построить гибридный ансамбль с роутингом по категории пользователя.

Пользователи разделяются на три группы:

- **Cold** — FPMC: марковские переходы работают даже на короткой истории
- **Warm** — SASRec: transformer улавливает последовательные паттерны
- **Hot** — LightGCN: графовая агрегация раскрывается на богатой истории

Выбор модели для каждой группы определяется по метрикам на валидационной выборке.

Обучение моделей и валидация

Обучение всех персонализированных моделей проводится в едином пайплайне с жестким временным разделением данных (temporal split) для предотвращения утечки данных из будущего (data leakage).

Стратегия разделения данных

- **Тренировочный период:** недели 00 – 24. Все взаимодействия за этот период используются для построения пользовательских профилей, графов и последовательностей.
- **Валидационный/тестовый период:** неделя 25. Взаимодействия этой недели используются исключительно как ground truth (целевые ответы) для оценки качества предсказаний.

Функция потерь и оптимизация

Для моделей FPMC, LightGCN и SASRec используется функция потерь **BPR (Bayesian Personalized Ranking)**. В отличие от попарной классификации (BCE), BPR оптимизирует непосредственно ранжирование, максимизируя разницу между скором позитивного и негативного айтема для одного пользователя:

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j) \in D} \ln \sigma(\hat{y}_{u,i} - \hat{y}_{u,j}) + \lambda \|\Theta\|^2$$

где:

- u — пользователь,
- i — позитивный айтем (из истории взаимодействий),
- j — негативный айтем (семплированный),
- $\hat{y}_{u,i}$ и $\hat{y}_{u,j}$ — предсказанные скоры,
- σ — сигмоида,
- Θ — параметры модели (для регуляризации).

Оптимизация проводится с использованием алгоритма **Adam** с базовой скоростью обучения $lr = 10^{-3}$. Модель **MostPopular** является эвристической и не требует этапа градиентного обучения.

Механизм Negative Sampling

Качество BPR-обучения критически зависит от корректности выбора негативных примеров. В проекте реализован единый строгий механизм семплирования (common/negatives.py):

1. **Приоритет явным негативам:** если у пользователя есть история явных отказов (дизлайки, свайпы), негативный айтем выбирается случайно из этого множества.
2. **Fallback на равномерное распределение:** если явных негативов нет, айтем выбирается равномерно из всего словаря $\mathcal{I}$.
3. **Строгое исключение позитивов (Критично):** из пула кандидатов на роль негативного айтема **исключаются все айтемы, с которыми пользователь имел позитивные взаимодействия в тренировочном периоде**. Это предотвращает ситуацию, когда модель штрафует за предсказание айтема, который пользователю на самом деле нравится.

Процедура валидации и метрики

Оценка качества проводится на валидационной неделе для каждого пользователя индивидуально.

Ключевое правило валидации: перед ранжированием из множества всех возможных кандидатов $\mathcal{I}$ удаляются все айтемы из множества S_u (все айтемы, с которыми пользователь взаимодействовал в тренировочном периоде, как позитивно, так и негативно). Модель оценивается только по способности находить новые релевантные айтемы.

Для оценки используются стандартные метрики ранжирования (при $K = 10$):

- **Recall@K:** доля целевых айтемов, попавших в топ- K рекомендаций.
- **NDCG@K (Normalized Discounted Cumulative Gain):** учитывает не только факт попадания в топ- K , но и позицию айтема (выше позиция — выше вклад в метрику).
- **MRR (Mean Reciprocal Rank):** среднее значение величины, обратной рангу первого релевантного айтема.

Построение гибридного ансамбля

После независимого обучения и валидации всех четырех моделей производится агрегация результатов для построения гибридной системы.

Пользователи валидационной выборки разделяются на три группы на основе размера их тренировочной истории (количество всех взаимодействий):

- **Cold**
- **Warm**
- **Hot**

Для каждой группы независимо вычисляются метрики (Recall@K, NDCG@K) по каждой из четырех моделей. Модель, показавшая наилучший результат для конкретной группы, фиксируется как используемая для пользователей этой категории в финальном инференсе.

Примечание: автоматическое обновление границ исходя из обновления статистики не реализовано. Задача деплоя на prod не рассматривалась, и реализация стратегии пересчета статистики и коррекции разбиения на группы остается в перспективных планах.

Результаты и анализ

Обучение и валидация моделей проводились на подвыборке VK-LSVD (up0.001_ip0.001) с разделением по времени (недели 00–24 для обучения, неделя 25 для валидации). Оценка производилась по метрикам Recall@10, NDCG@10 и MRR с исключением из выдачи всех айтемов, с которыми пользователь уже взаимодействовал.

Сводная таблица метрик по группам пользователей

Ниже представлены результаты оценки каждой модели на сегментах пользователей с разной длиной истории взаимодействий. Модель

Группа	Модель	n_users	Recall@10	NDCG@10	MRR@10
cold	MostPopular	94	0.00190	0.00142	0.00267
cold	FPMC	94	0.00623	0.01203	0.01005
cold	LightGCN	94	0.00467	0.00822	0.00143
cold	SASRec	93	0.00570	0.00609	0.01410
warm	MostPopular	97	0.01440	0.01405	0.01124
warm	FPMC	97	0.00320	0.00571	0.00078
warm	LightGCN	97	0.00400	0.00611	0.00191
warm	SASRec	97	0.00317	0.00482	0.01625
hot	MostPopular	99	0.00962	0.02333	0.00518
hot	FPMC	99	0.00184	0.01025	0.00385
hot	LightGCN	99	0.00394	0.01776	0.00221
hot	SASRec	99	0.00955	0.02369	0.04624

(Примечание: значения метрик округлены до 5-го знака после запятой).

Формирование гибридного ансамбля

На основе сравнения метрик для каждой группы пользователей была выбрана модель, показавшая наилучший результат по NDCG@10. Сформирован следующий маршрутизатор (router) для финального инференса:

- **Cold:** оптимальной оказалась модель [FPMC / SASRec].
- **Warm:** оптимальной оказалась модель [MostPopular / SASRec].
- **Hot:** оптимальной оказалась модель [SASRec / MostPopular].

Ограничения и выводы

1. **Влияние объема данных:** Абсолютные значения метрик могут быть ниже промышленных бенчмарков. Это ожидаемо, так как эксперимент проводился на разреженной подвыборке (0.1% пользователей и 0.1% популярных видео), что ограничивает способность глубоких моделей (SASRec, LightGCN) выявлять сложные паттерны.
2. **Относительная эффективность:** Несмотря на малый объем данных, относительное сравнение моделей остается корректным. Графовые и последовательные модели демонстрируют преимущество на группах Warm и Hot, в то время как на группе Cold простые эвристики или марковские цепи (FPMC) показывают сопоставимый или лучший результат из-за недостатка контекста.
3. **Корректность оценки:** Строгое исключение айтемов из множества seen при валидации гарантирует, что метрики отражают реальную способность системы рекомендовать новый контент, а не просто запоминать историю.
4. **Отсутствие LightGCN:** Отсутствие графовой модели хотя бы в одной из групп может быть объяснено, как я считаю, мизерным количеством реально предоставленных модели данных и малым значением количества эпох, для графовой модели 5 эпох тренировки - это совсем ни о чем.

Заключение

В рамках работы была реализована и исследована гибридная рекомендательная система для видеохостинга, объединяющая четыре класса алгоритмов: неперсональный baseline (MostPopular), персональные марковские модели (FPMC), последовательные модели на основе self-attention (SASRec) и графовые модели (LightGCN).

Ключевым результатом работы является построение **гибридного ансамбля с роутингом по категории пользователей**. На основе анализа метрик (Recall@10, NDCG@10, MRR) на валидационной выборке с временным разделением показано, что оптимальная модель зависит от длины истории взаимодействий пользователя:

- для «холодных» пользователей наиболее эффективными оказываются марковские модели (FPMC) или SASRec;
- для «тёплых» пользователей преимущество получают последовательные модели (SASRec), учитывающие порядок взаимодействий, или MostPopular, хотя этот момент требует перепроверки;
- для «горячих» пользователей наилучшие результаты демонстрирует SASRec.

В ходе реализации были решены ряд методологических задач, критичных для корректности оценки:

- единая разметка позитивных и негативных взаимодействий с правилом «позитив побеждает»;
- строгое исключение уже увиденных айтемов из кандидатов при расчёте метрик;
- корректный negative sampling с исключением всех позитивных айтемов пользователя, а не только текущего целевого.

Ограничением работы является использование подвыборки датасета (0.1% пользователей и 0.1% популярных видео), что снижает абсолютные значения метрик, но не влияет на корректность относительного сравнения моделей. Полученные результаты согласуются с известными из литературы наблюдениями о том, что сложные модели требуют достаточного объёма данных для раскрытия потенциала, в то время как на коротких историях простые подходы остаются конкурентоспособными.

Направлениями дальнейшего развития могут стать:

- расширение эксперимента на полный датасет VK-LSVD;
- использование контентных эмбедингов видеороликов для инициализации весов моделей и смягчения проблемы cold-start;
- учёт контекстных признаков (платформа, место входа) и метаданных пользователей;

- переход к многозадачной постановке с одновременным прогнозированием нескольких типов взаимодействий.
- проверка инсайтов найденных в EDA (результаты EDA в проекте не использовались, но ознакомится с ними можно в файле notebooks/01_eda.ipynb).

Список литературы

1. **Koren, Y., Bell, R. M., Volinsky, C.** Matrix Factorization Techniques for Recommender Systems // Computer. — 2009. — Vol. 42, No. 8. — P. 30–37.
2. **Rendle, S., Freudenthaler, C., Gantner, Z., Schmidt-Thieme, L.** BPR: Bayesian Personalized Ranking from Implicit Feedback // Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI). — 2009. — P. 452–461.
3. **Rendle, S., Freudenthaler, C., Schmidt-Thieme, L.** Factorizing Personalized Markov Chains for Next-Basket Recommendation // Proceedings of the 19th International Conference on World Wide Web (WWW). — 2010. — P. 811–820.
4. **Vaswani, A., Shazeer, N., Parmar, N. et al.** Attention Is All You Need // Advances in Neural Information Processing Systems (NeurIPS). — 2017. — Vol. 30.
5. **Kang, W.-C., McAuley, J.** Self-Attentive Sequential Recommendation // Proceedings of the IEEE International Conference on Data Mining (ICDM). — 2018. — P. 197–206.
6. **He, X., Deng, K., Wang, X. et al.** LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. — 2020. — P. 639–648.
7. **AIRI Institute.** VK-LSVD: Large Short-Video Dataset // Hugging Face Datasets. — URL: <https://huggingface.co/datasets/AIRI-Institute/VK-LSVD> (дата обращения: 16.09.2026).
8. **Tunstall, L., von Werra, L., Wolf, T.** Natural Language Processing with Transformers. — O'Reilly Media, 2022. — 300 p.
9. **Rothman, D. J.** Transformers for Natural Language Processing. — Packt Publishing, 2021. — 406 p.
10. **Zhang, S., Yao, L., Sun, A., Tay, Y.** Deep Learning Based Recommender System: A Survey and New Perspectives // ACM Computing Surveys. — 2019. — Vol. 52, No. 1. — P. 1–38.